

## 1. 定义

假设  $X_1, X_2, \dots, X_n$  是从一个总体中抽取的独立同分布 (i.i.d.) 的随机样本。将这些样本按从小到大的顺序排列，得到一组新的随机变量：

$$X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$$

这组有序的随机变量就称为**次序统计量**。

- $X_{(1)} = \min(X_1, X_2, \dots, X_n)$  是样本最小值。
- $X_{(n)} = \max(X_1, X_2, \dots, X_n)$  是样本最大值。
- $X_{(k)}$  是第  $k$  小的观测值。
- 如果  $n$  是奇数，样本中位数是  $X_{((n+1)/2)}$ 。
- 样本极差是  $R = X_{(n)} - X_{(1)}$ 。
- 样本中程数是  $\frac{1}{2}(X_{(1)} + X_{(n)})$ ，就是你原题中用到的量。

## 2. 次序统计量的分布

这是最核心的部分。设原始样本来自一个连续分布，其累积分布函数 (CDF) 为  $F(x)$ ，概率密度函数 (PDF) 为  $f(x)$ 。

### a. 第 $k$ 个次序统计量 $X_{(k)}$ 的分布

**直观理解 (推导PDF的思路):**

要让第  $k$  小的值  $X_{(k)}$  恰好落在很小的区间  $[x, x + dx]$  内，必须发生三件事：

1. 有 **1** 个样本值落入  $[x, x + dx]$  内，其概率约为  $f(x)dx$ 。
2. 有  **$k-1$**  个样本值小于  $x$ ，其概率为  $F(x)$ 。
3. 有  **$n-k$**  个样本值大于  $x + dx$  (约等于大于  $x$ )，其概率为  $1 - F(x)$ 。

这  $n$  个样本值可以有多种组合方式来实现上述配置。从  $n$  个中选 1 个落在  $[x, x + dx]$ ，再从剩下的  $n - 1$  个中选  $k - 1$  个小于  $x$ ，组合数为  $\binom{n}{1} \binom{n-1}{k-1} = \frac{n!}{(k-1)!(n-k)!}$ 。

综合起来，就得到了  $X_{(k)}$  的概率密度函数 (PDF)：

$$f_{X_{(k)}}(x) = \frac{n!}{(k-1)!(n-k)!} [F(x)]^{k-1} [1 - F(x)]^{n-k} f(x)$$

**特殊情况 (非常常用):**

- **样本最小值  $X_{(1)}$  的PDF ( $k = 1$ ):**
$$f_{X_{(1)}}(x) = \frac{n!}{0!(n-1)!} [F(x)]^0 [1 - F(x)]^{n-1} f(x) = n[1 - F(x)]^{n-1} f(x)$$
- **样本最大值  $X_{(n)}$  的PDF ( $k = n$ ):**
$$f_{X_{(n)}}(x) = \frac{n!}{(n-1)!0!} [F(x)]^{n-1} [1 - F(x)]^0 f(x) = n[F(x)]^{n-1} f(x)$$

## b. $X_{(1)}$ 和 $X_{(n)}$ 的累积分布函数 (CDF)

有时候 CDF 更容易推导和使用。

- **最大值  $X_{(n)}$  的 CDF:**

事件 " $X_{(n)} \leq x$ " 等价于事件 "所有样本值都  $\leq x$ "。

$$F_{X_{(n)}}(x) = P(X_{(n)} \leq x) = P(X_1 \leq x, \dots, X_n \leq x) = [P(X \leq x)]^n = [F(x)]^n$$

- **最小值  $X_{(1)}$  的 CDF:**

直接求  $P(X_{(1)} \leq x)$  不方便，我们求其对立事件。

$$F_{X_{(1)}}(x) = P(X_{(1)} \leq x) = 1 - P(X_{(1)} > x)$$

事件 " $X_{(1)} > x$ " 等价于事件 "所有样本值都  $> x$ "。

$$P(X_{(1)} > x) = P(X_1 > x, \dots, X_n > x) = [P(X > x)]^n = [1 - F(x)]^n$$

$$\text{所以, } F_{X_{(1)}}(x) = 1 - [1 - F(x)]^n$$

## 3. 最重要的特例：标准均匀分布 $U(0, 1)$

当原始样本  $X_1, \dots, X_n$  来自  $U(0, 1)$  分布时，次序统计量的性质有非常简洁和优美的形式。这是因为对于  $x \in (0, 1)$ ，我们有  $F(x) = x$  且  $f(x) = 1$ 。

将此代入  $X_{(k)}$  的 PDF 公式：

$$f_{X_{(k)}}(x) = \frac{n!}{(k-1)!(n-k)!} x^{k-1} (1-x)^{n-k}$$

这个形式你可能很眼熟，它就是 **Beta 分布** 的 PDF！具体来说：

$$X_{(k)} \sim \text{Beta}(k, n - k + 1)$$

Beta 分布  $B(\alpha, \beta)$  的期望和方差公式是：

- $E(Z) = \frac{\alpha}{\alpha + \beta}$
- $D(Z) = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$

将  $\alpha = k$  和  $\beta = n - k + 1$  代入，我们得到  $U(0, 1)$  样本的次序统计量的期望和方差：

- **期望:**  $E(X_{(k)}) = \frac{k}{k + (n - k + 1)} = \frac{k}{n + 1}$
- **方差:**  $D(X_{(k)}) = \frac{k(n - k + 1)}{(n + 1)^2(n + 2)}$

这就是你原题中计算  $E(X_{(1)})$  和  $E(X_{(n)})$  的理论基础！

## 4. 从 $U(0, 1)$ 到任意分布的推广（变换法）

我们可以利用  $U(0, 1)$  的结果来计算其他分布的次序统计量的性质。

- **概率积分变换:** 如果一个随机变量  $Y$  的 CDF 是  $F_Y(y)$ ，那么随机变量  $U = F_Y(Y)$  服从  $U(0, 1)$  分布。
- **逆变换:** 如果  $U \sim U(0, 1)$ ，那么  $Y = F_Y^{-1}(U)$  就服从 CDF 为  $F_Y$  的分布。

这个关系对于次序统计量也成立：

如果  $Y_{(k)}$  是来自  $Y$  的次序统计量， $U_{(k)}$  是来自  $U(0,1)$  的次序统计量，则  $Y_{(k)} = F_Y^{-1}(U_{(k)})$ 。

在你原题中， $X \sim U(\theta - 1/2, \theta + 1/2)$ 。

这是一个线性变换。令  $U \sim U(0,1)$ ，则  $X = (\theta + 1/2 - (\theta - 1/2))U + (\theta - 1/2) = U + \theta - 1/2$ 。

因此， $X_{(k)} = U_{(k)} + \theta - 1/2$ 。

所以：

$$E(X_{(k)}) = E(U_{(k)} + \theta - 1/2) = E(U_{(k)}) + \theta - 1/2 = \frac{k}{n+1} + \theta - 1/2$$

这就解释了我们是如何得到  $E(X_{(1)})$  和  $E(X_{(n)})$  的。

## 5. 联合分布与协方差

两个次序统计量  $X_{(i)}$  和  $X_{(j)}$  ( $i < j$ ) 的联合PDF也可用类似的直观方法推导：

$$f_{X_{(i)}, X_{(j)}}(x, y) = \frac{n!}{(i-1)!(j-i-1)!(n-j)!} [F(x)]^{i-1} [F(y) - F(x)]^{j-i-1} [1 - F(y)]^{n-j} f(x) f(y)$$

对于  $x < y$ 。

对于  $U(0,1)$  分布，这个公式可以用来计算协方差，其结果为：

$$\text{Cov}(X_{(i)}, X_{(j)}) = \frac{i(n-j+1)}{(n+1)^2(n+2)} \quad (\text{for } i \leq j)$$

这个协方差公式在计算  $D(\hat{\theta}_2) = D(\frac{1}{2}(X_{(1)} + X_{(n)}))$  时被用到，因为：

$$D(\frac{1}{2}(X_{(1)} + X_{(n)})) = \frac{1}{4}[D(X_{(1)}) + D(X_{(n)}) + 2\text{Cov}(X_{(1)}, X_{(n)})]$$

## 总结：你需要记住的核心结论

对于一个来自  $U(0,1)$  分布的样本的次序统计量  $X_{(k)}$ ：

1. 分布:  $X_{(k)} \sim \text{Beta}(k, n - k + 1)$

2. 期望:  $E(X_{(k)}) = \frac{k}{n+1}$

3. 方差:  $D(X_{(k)}) = \frac{k(n-k+1)}{(n+1)^2(n+2)}$

4. 协方差:  $\text{Cov}(X_{(i)}, X_{(j)}) = \frac{i(n-j+1)}{(n+1)^2(n+2)} \quad (\text{for } i \leq j)$

对于其他分布，特别是线性变换（如均匀分布  $U(a, b)$  或指数分布），可以通过变换法利用上述  $U(0,1)$  的结论来求解。

希望这份详细的梳理能帮助你彻底理解次序统计量，并能熟练应用它们解决问题！

# 记忆技巧

当然！对于这种看起来复杂又没有明显规律的公式，最好的记忆方法不是死记硬背，而是理解其背后的直观思想和模式。一旦你抓住了核心的直观模型，这些公式就会变得非常自然，甚至可以当场推导出来。

下面我为你介绍一个非常有效的记忆框架，它基于一个简单的比喻：“分蛋糕”或“插旗子”。

## 核心直观模型：在 $(0, 1)$ 区间上插旗子

想象一下，区间  $(0, 1)$  是一块长度为 1 的长条蛋糕。你随机地往上面撒下  $n$  颗巧克力豆（这就是你的样本  $X_1, \dots, X_n$ ）。

$X_{(1)}, X_{(2)}, \dots, X_{(n)}$  就是这些巧克力豆从左到右排好序的位置。

这  $n$  颗巧克力豆，会把整个蛋糕分成了  $n + 1$  个小段：

- 第1段：从 0 到  $X_{(1)}$
- 第2段：从  $X_{(1)}$  到  $X_{(2)}$
- ...
- 第  $k$  段：从  $X_{(k-1)}$  到  $X_{(k)}$
- ...
- 第  $n + 1$  段：从  $X_{(n)}$  到 1

**核心洞察：**由于这些点是随机均匀撒下的，平均来看，这  $n + 1$  段的长度是相等的。因为总长度是 1，所以每一小段的平均长度都是  $\frac{1}{n+1}$ 。

有了这个“平均每段长  $\frac{1}{n+1}$ ”的核心思想，我们来破解所有公式。

## 1. 期望 $E[X_{(k)}]$ ：第 $k$ 个旗子的位置

公式：  $E[X_{(k)}] = \frac{k}{n+1}$

记忆方法：“第  $k$  个旗子的位置 = 前  $k$  段蛋糕的长度之和”

$X_{(k)}$  这个点的位置，就是从 0 开始，数过  $k$  小段蛋糕的终点。

既然平均每段长度是  $\frac{1}{n+1}$ ，那么  $k$  段的总长度自然就是  $k \times \frac{1}{n+1}$ 。

- 例子：  $E[X_{(1)}]$ ? 第一个旗子的位置。就是第一段的长度，所以是  $\frac{1}{n+1}$ 。
- 例子：  $E[X_{(n)}]$ ? 最后一个旗子的位置。就是前  $n$  段的长度，所以是  $\frac{n}{n+1}$ 。

这个最简单，也最重要。

---

## 2. 方差 $D(X_{(k)})$ 和协方差 $Cov(X_{(i)}, X_{(j)})$ ：波动的程度

这两个公式看起来最吓人，但它们共享一个结构，特别是分母。

公式：

- $D(X_{(k)}) = \frac{k(n-k+1)}{(n+1)^2(n+2)}$
- $Cov(X_{(i)}, X_{(j)}) = \frac{i(n-j+1)}{(n+1)^2(n+2)}$  (其中  $i \leq j$ )

记忆方法 (分两步走)：

第一步：记住那个“大魔王”分母

分母都是  $(n+1)^2(n+2)$ 。

你可以这样记：从期望的分母  $n+1$  出发，先把它平方，再乘上比它大1的数  $n+2$ 。

口诀：“(n+1) 平方，再乘 (n+2)”

第二步：记住分子（非常有规律！）

方差的分子  $k(n-k+1)$ ：

口诀：“左边的段数 × 右边的段数”

- $X_{(k)}$  这个点，把它左边的蛋糕段数数出来，正好是  $k$  段。
- 把它右边的蛋糕段数数出来，是  $(n+1) - k = n - k + 1$  段。
- 分子就是这两者相乘。
- **直观理解**：一个点的位置波动大小，和它两边空间的“自由度”有关。当点在中间时（ $k \approx n/2$ ），两边空间都很大，波动最大，这个乘积也最大。当点在两端时（ $k = 1$  或  $k = n$ ），一边空间被压缩，波动就小。

协方差的分子  $i(n-j+1)$ ：

口诀：“左边点的左边段数 × 右边点的右边段数”

- 对于  $X_{(i)}$  和  $X_{(j)}$  (假设  $i \leq j$ )
  - 取最左边的点  $X_{(i)}$ ，看它左边有几段： $i$  段。
  - 取最右边的点  $X_{(j)}$ ，看它右边有几段： $n - j + 1$  段。
  - 分子就是这两者相乘。
  - **你会发现，方差是协方差在  $i = j = k$  时的特例！** 所以你只需要记住协方差的规律就行了。
-

### 3. 极差的期望 $E[R] = E[X_{(n)} - X_{(1)}]$

公式:  $E[R] = \frac{n-1}{n+1}$

记忆方法1: 用期望公式硬算

$$E[R] = E[X_{(n)}] - E[X_{(1)}] = \frac{n}{n+1} - \frac{1}{n+1} = \frac{n-1}{n+1}。$$

这个最直接。

记忆方法2: 继续用“分蛋糕”模型

口诀: “内部蛋糕段的总长度”

- 极差  $R = X_{(n)} - X_{(1)}$  是最外面那个点和最里面那个点之间的距离。
- 这段距离包含了多少个“小段”? 它包含了从  $X_{(1)}$  到  $X_{(2)}$ , ..., 一直到  $X_{(n-1)}$  到  $X_{(n)}$  的所有段。总共有  $n - 1$  段。
- 既然平均每段长度是  $\frac{1}{n+1}$ , 那么  $n - 1$  段的总长度自然就是  $\frac{n-1}{n+1}$ 。

### 总结与表格

统计量	公式	记忆口诀/方法
期望 $E[X_{(k)}]$	$\frac{k}{n+1}$	第k个位置 = k段蛋糕
极差期望 $E[R]$	$\frac{n-1}{n+1}$	内部n-1段蛋糕
方差/协方差分母	$(n+1)^2(n+2)$	(n+1)平方, 再乘(n+2)
方差分子 $D(X_{(k)})$	$k(n-k+1)$	左边段数 × 右边段数
协方差分子 $Cov(X_{(i)}, X_{(j)})$	$i(n-j+1)$	左点的左边段数 × 右点的右边段数

希望这个框架能帮你把这些看似杂乱的公式串成一个有逻辑、有图像的整体, 从而轻松记住它们!